文件系统-知识地图

https://github.com/wangcy6/weekly/blob/master/KM/01%E7%B3%BB%E7%BB%9F%E7%9F%A5%E8%AF%86/file.md

阅读相关书籍

- Linux 0.11内核完全注释
- Linux内核设计与实现(第三版中文高清带目录)
- Linux设备驱动程序.
- Understanding the Linux Kernel, 3rd Editio
- Linux.Kernel.Cache
- MySQL技术内幕(InnoDB存储引擎)第2版.
- 性能之巅 洞悉系统、企业与云计算(完整版)

找不到电子版book

第一性原理

- mysql 有b+作为索引，为什么liunx文件系统不用b+索引结构，采用inode下面一个固定大小数组来表示？
- 为什么需要进行“格式化”呢
- ls -i 显示inode 就是 long 类型的编号 还有什么呀？
- 文件存储在哪里呀？内存还是磁盘
- 什么是缓存呀

概念理解

8.1 术语

为了方便参考，本章使用的文件系统相关术语介绍如下。

- **文件系统**：一种把数据组织成文件和目录的存储方式，提供了基于文件的存取接口，并通过文件权限控制访问。另外，还包括一些表示设备、套接字和管道的特殊文件类型，以及包含文件访问时间戳的元数据。
- **文件系统缓存**：主存（通常是 DRAM）的一块区域，用来缓存文件系统的内容，可能包含各种数据和元数据。
- **操作**：文件系统的操作是对文件系统的请求，包括 `read()`、`write()`、`open()`、`close()`、`stat()`、 `mkdir()`以及其他操作。
- **I/O**：输入/输出。文件系统 I/O 有好几种定义，这里仅仅指直接读写（执行 I/O）的操作，包括 `read()`、`write()`、`stat()`（读的统计信息）和 `mkdir()`（创建一个新的目录项）。I/O 不包括 `open()` 和 `close()`。
- **逻辑 I/O**：由应用程序发给文件系统的 I/O。
- **物理 I/O**：由文件系统直接发给磁盘的 I/O（或者通过裸 I/O）。
- **吞吐量**：当前应用程序和文件系统之间的数据传输率，单位是 B/s。
- **inode**：一个索引节点（inode）是一种含有文件系统对象元数据的数据结构，其中有访问权限、时间戳以及数据指针。
- **VFS**：虚拟文件系统，一个为了抽象与支持不同文件系统类型的内核接口。在 Solaris 上，一个 VFS inode 被称为一个 vnode。
- **卷管理器**：灵活管理物理存储设备的软件，在设备上创建虚拟卷供操作系统使用。

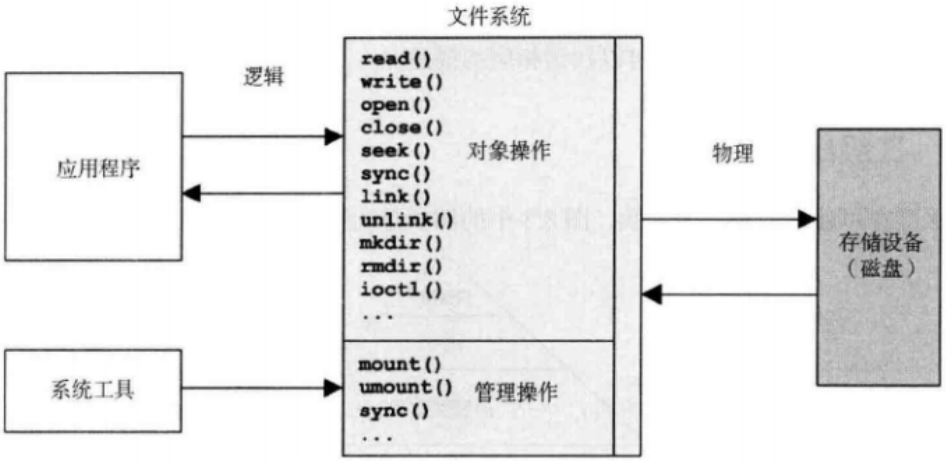

图 8.1 文件系统接口

- 缓存

文件系统启动之后会使用主存（RAM）当缓存以提高性能。对应用程序这是透明的：它们的逻辑 I/O 延时小了很多，因为可以直接从主存返回而不是从慢得多的磁盘设备返回。

随着时间的流逝，缓存大小不断增长而操作系统的空余内存不断减小，这会影响新用户，不过这再正常不过了。原则如下：如果还有空闲内存，就用来存放有用的内容。当应用程序需要更多的内存时，内核应该迅速从文件系统缓存中释放一些以备使用。

文件系统用缓存（caching）提高读性能，而用缓冲（buffering）（在缓存中）提高写性能。文件系统和块设备子系统一般使用多种类型的缓存，表 8.1 中有一些具体的例子。

8.4 节描述了一些专用缓存类型。第 3 章里有完整的缓存列表（包括了应用程序和设备级别）。

表 8.1　缓存类型示例

缓存	示例
页缓存	操作系统页缓存
文件系统主存	ZFS ARC
文件系统二级缓存	ZFS L2ARC
目录缓存	目录缓存，DNLC
inode 缓存	inode 缓存
设备缓存	ZFS vdev
块设备缓存	块缓存（buffer cache）

文件系统

在 Linux 中一切皆文件。不仅普通的文件和目录，就连块设备、套接字、管道等，也都要通过统一的文件系统来管理。

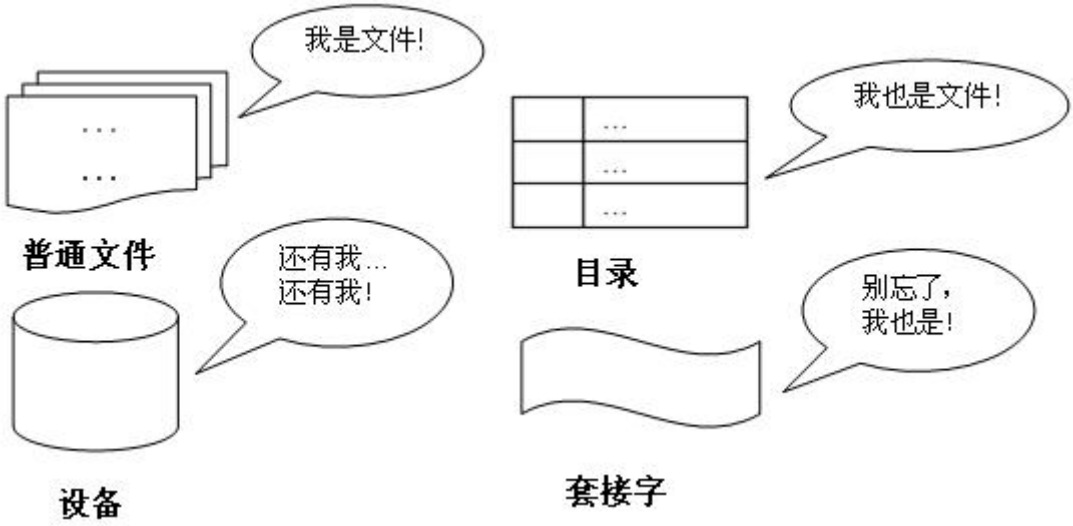

Linux 下的文件系统主要可分为三大块：

一是上层的文件系统的系统调用，

二是虚拟文件系统 VFS(Virtual Filesystem Switch)，

三是挂载到 VFS 中的各实际文件系统

图 8.6 刻画了文件系统 I/O 栈的一般模型。具体的模块和层次依赖于使用的操作系统类型、版本以及文件系统。完整的图可参考第 3 章。

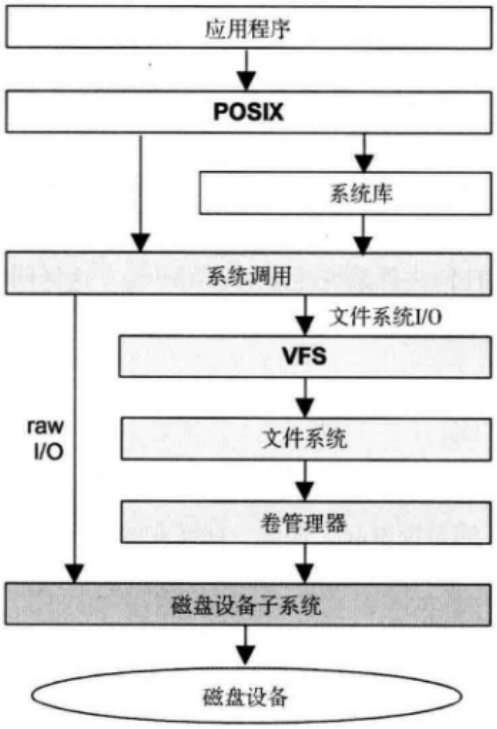

图 8.6 通用文件系统 I/O 栈

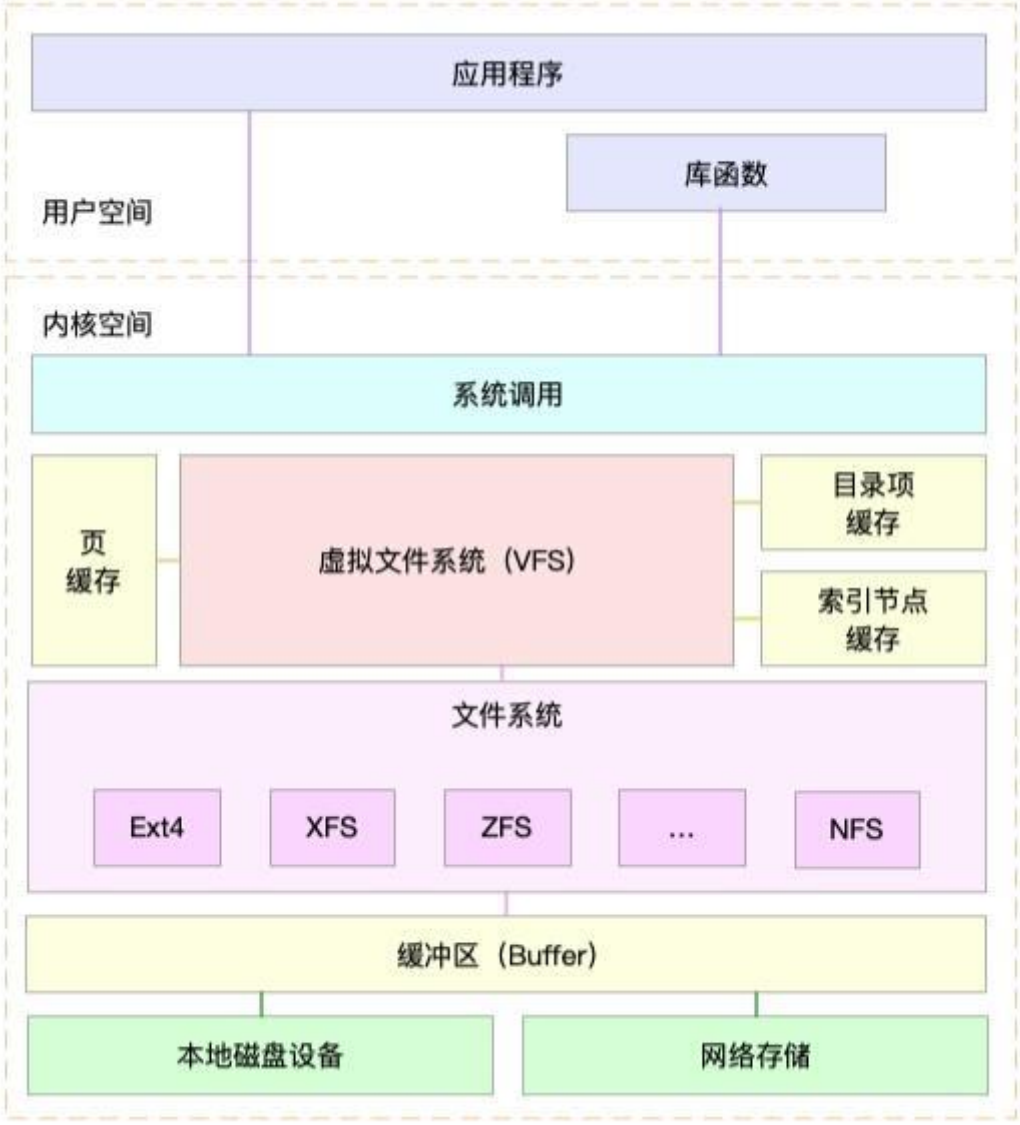

第一个问题：文件系统类型有哪些？

> 字符设备、块设备、网络设备

```
 df -h
Filesystem                Size  Used Avail Use% Mounted on
/dev/mapper/vg_root-root   19G  6.5G   12G  37% /
devtmpfs                  7.8G     0  7.8G   0% /dev
tmpfs                     7.8G     0  7.8G   0% /dev/shm
tmpfs                     7.8G  4.3G  3.6G  55% /run
tmpfs                     7.8G     0  7.8G   0% /sys/fs/cgroup
/dev/sda1                 190M  100M   77M  57% /boot
/dev/vda1                 493G  350M  467G   1% /app
tmpfs                     1.6G     0  1.6G   0% /run/user/0
tmpfs                     1.6G     0  1.6G   0% /run/user/888

tmpfs是最好的基于RAM的文件系统。是一种基于内存的文件系
/dev目录下的每一个文件都对应的是一个设备
proc文件系统为操作系统本身和应用程序之间的通信提供了一个安全的接口
https://blog.csdn.net/qq_27840681/article/details/77567094
```

.上层应用如何调用底层驱动？

VFS

组成

VFS（虚拟文件系统接口，virtual file system interface）给不同类型的文件系统提供了一个通用的接口。图 8.7 里演示了它的位置。

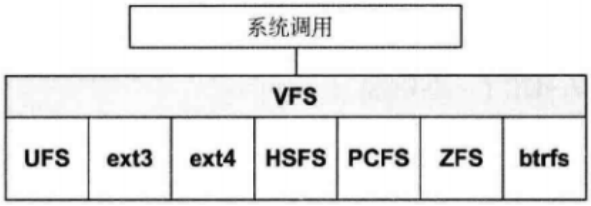

文件系统是如何运行的

> 那么文件系统是如何运行的呢？这与操作系统的文件数据有关。较新的操作系统的文件数据 除了文件实际内容外， 通常含有非常多的属性，
>
> 例如 Linux 操作系统的文件权限（rwx）与文 件属性（拥有者、群组、时间参数等）。
>
> 文件系统通常会将这两部份的数据分别存放在不同 的区块，权限与属性放置到 inode 中，
>
> 至于实际数据则放置到 data block 区块中。 另外，还 有一个超级区块（superblock）会记录整个文件系统的整体信息，包括 inode 与 block 的总 量、使用量、剩余量等

- 构成

VFS（virtual File System）

目录项、索引节点、逻辑块以及超级块，构成了 Linux 文件系统的四大基本要素。

目录项对象 (dentry object)

> 目录项，简称为 dentry，用来记录文件的名字、索引节点指针以及与其他目录项的关联关系。
>
> 多个关联的目录项，就构成了文件系统的目录结构。
>
> 不过，不同于索引节点，目录项是由内核维护的一个内存数据结构，所以通常也被叫做目录项缓存。
>
> 一个目录文件包含了一组目录项，目录项是放在data block中的。(参考《Unix环境高级编程》Page87)

索引节点对象 (inode object)

> 索引节点，简称为 inode，用来记录文件的元数据，
>
> 比如 inode 编号、文件大小、访问权限、修改日期、数据的位置等。

> 索引节点和文件一一对应，它跟文件内容一样，都会被持久化存储到磁盘中。
>
> 所以记住，索引节点同样占用磁盘空间。

文件对象 (file object)：

数据块是记录文件真实内容的地方

在格式化时 block 的大小就固定了，且每个 block 都有编号，以方便 inode 的记录啦

比较：

文件系统通常会将这两部份的数据分别存放在不同 的区块，权限与属性放置到 inode 中，至于实际数据则放置到 data block 区块中

超级块对象 (superblock object)

会记录整个文件系统的整体信息，包括 inode 与 block 的总 量、使用量、剩余量等。

> 磁盘在执行文件系统格式化时，会被分成三个存储区域，超级块、索引节点区和数据块区。其中，
>
> 超级块，存储整个文件系统的状态。 索引节点区，用来存储索引节点。 数据块区，则用来存储文件数据。

- 关系：

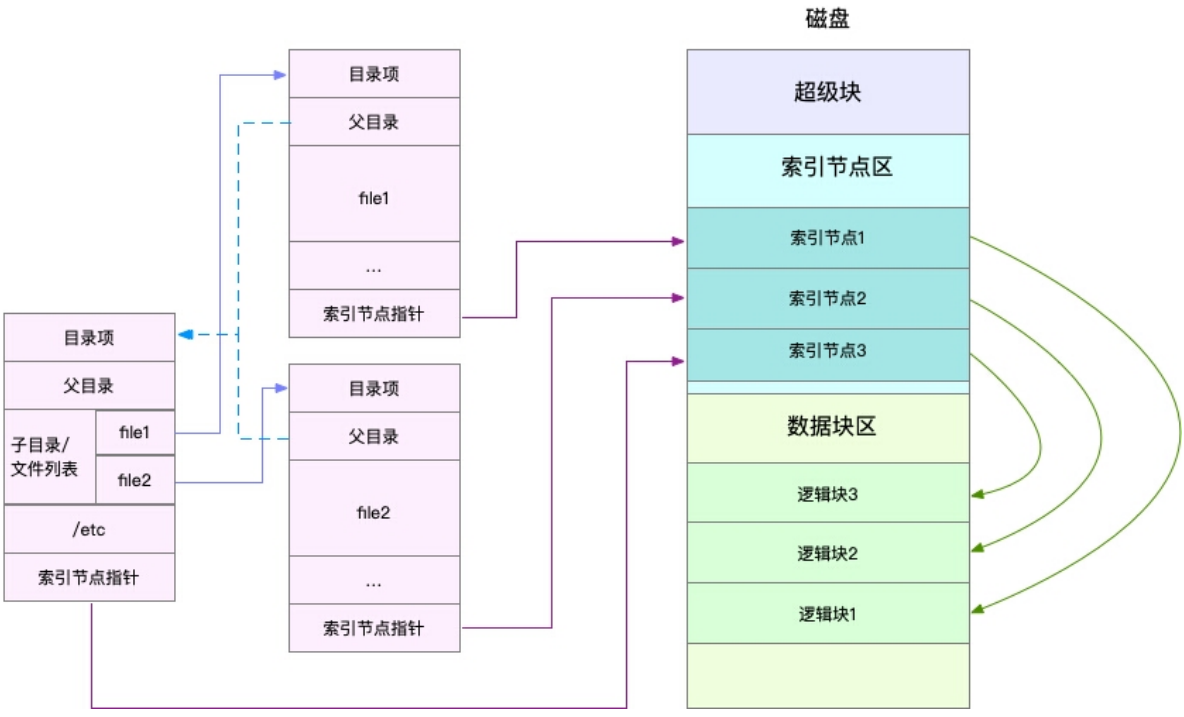

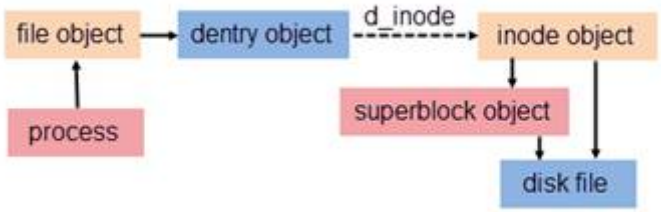

1. inode 结构

每个inode保存了文件系统中的一个**文件系统对象**（包括文件、目录、设备文件、socket、管道, 等等）的元信息数据，但不包括数据内容或者文件名[1]。

文件系统创建（格式化）时，就把存储区域分为两大连续的存储区域。

一个用来保存文件系统对象的元信息数据，这是由inode组成的表，

每个inode节点的大小，一般是128字节或256字节。inode节点的总数，

在格式化时就给定，一般是每1KB或每2KB就设置一个inode。

> 假定在一块1GB的硬盘中，每个inode节点的大小为128字节，
>
> 每1KB就设置一个inode，那么inode table的大小就会达到128MB，占整块硬盘的12.8%。

另一个用来保存"文件系统对象"的内容数据，划分为512字节的扇区，以及由8个扇区组成的4K字节的块。块是读写时的基本单位。一个文件系统的inode的总数是固定的。

这限制了该文件系统所能存储的文件系统对象的总数目。典型的实现下，所有inode占用了文件系统1%左右的存储容量。

> 一个数据快大小4k，一个inode节点256字节，根本装不下快，因此不包括数据内容

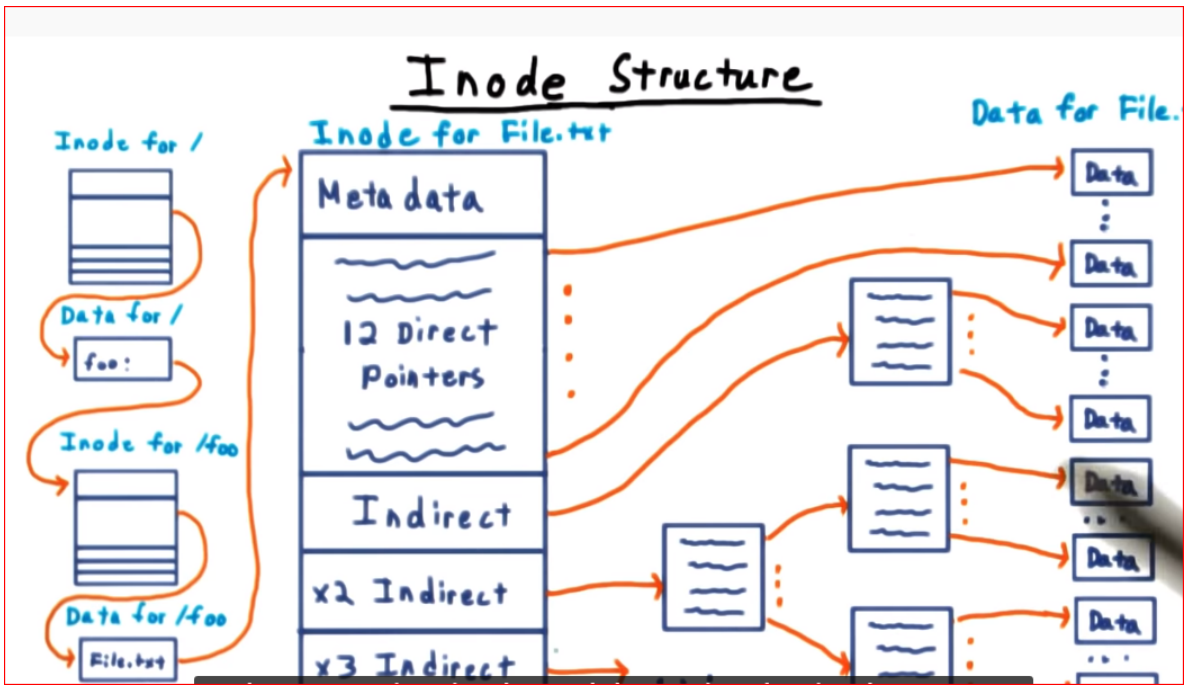
Inode Structure
Inode for /
Data for /
foo:
Inode for /foo
Data for /foo
File.txt
Inode for File.txt
Meta data
12 Direct Pointers
Indirect
x2 Indirect
x3 Indirect
Data for File.
Data

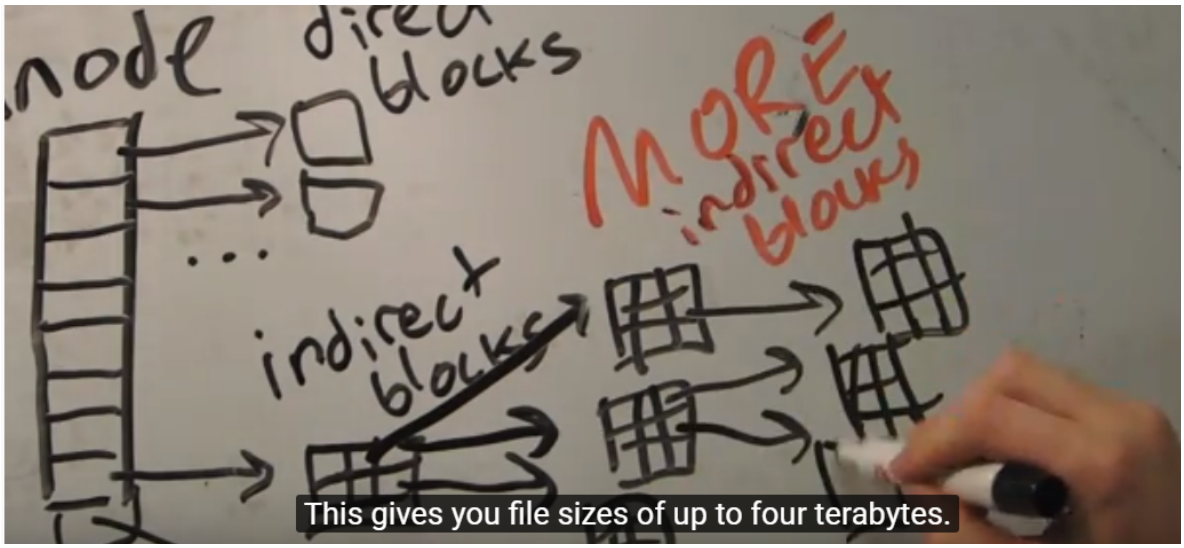
inode
direct blocks
MORE indirect blocks
indirect blocks
This gives you file sizes of up to four terabytes.

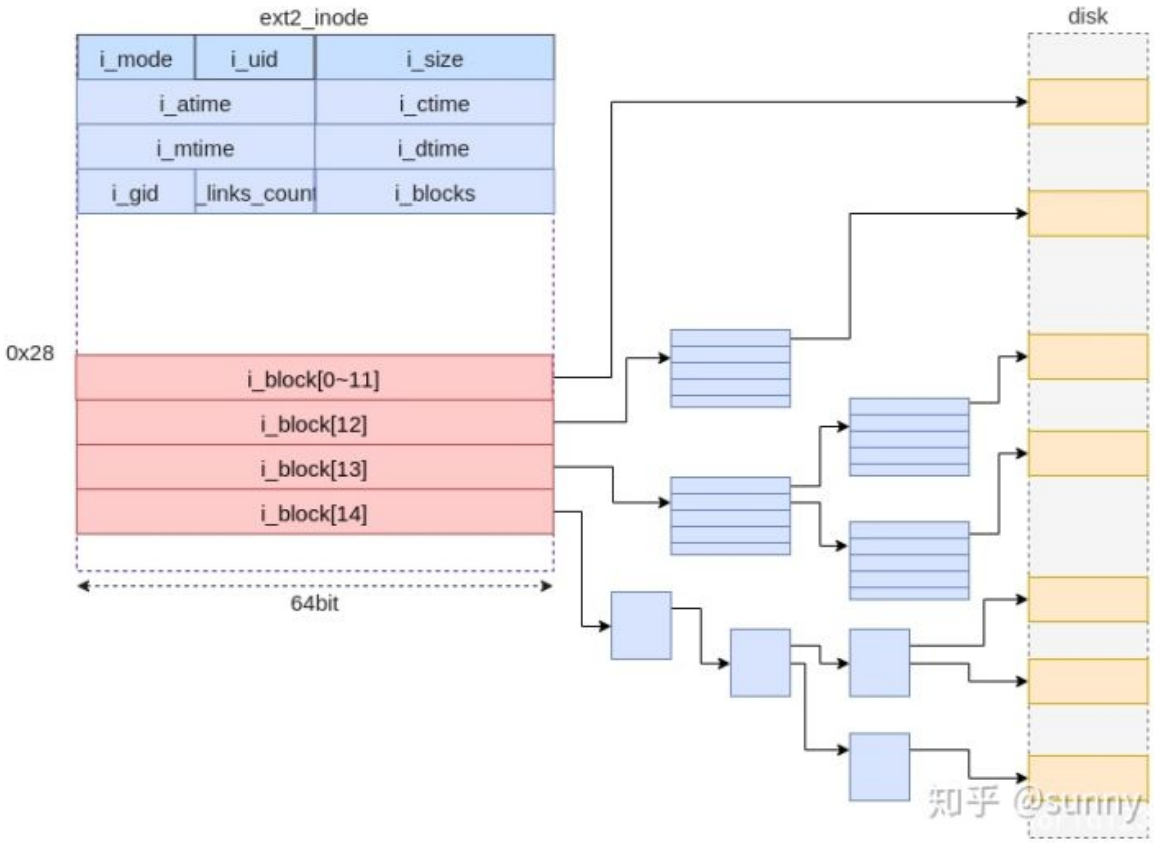

小王： 你明白了吧 inode 不仅仅是 *inode 编号*

ls -i src 30933073 github.com

30933073 是而*索引编号*实际上是 inode 的标识编号，

因此也称其为 *inode 编号* 或者 *索引编号*。

索引编号只是文件相关信息中一项重要的内容

VFS 中的 inode 与 inode_operations 结构体

```
struct inode {
    ...
    const struct inode_operations    *i_op; // 索引节点操作
    unsigned long           i_ino;      // 索引节点号
    atomic_t                i_count;    // 引用计数器
    unsigned int            i_nlink;    // 硬链接数目
    ...
}

struct inode_operations {
    ...
    int (*create) (struct inode *,struct dentry *,int, struct nameidata *);
    int (*link) (struct dentry *,struct inode *,struct dentry *);
```

```
    int (*unlink) (struct inode *,struct dentry *);
    int (*symlink) (struct inode *,struct dentry *,const char *);
    int (*mkdir) (struct inode *,struct dentry *,int);
    int (*rmdir) (struct inode *,struct dentry *);
    ...
}
```

```
struct ext4_inode {
    ``...
    ``__le32  i_atime;        // 文件内容最后一次访问时间
    ``__le32  i_ctime;        // inode 修改时间
    ``__le32  i_mtime;        // 文件内容最后一次修改时间
    ``__le16  i_links_count;  // 硬链接计数
    ``__le32  i_blocks_lo;    // Block 计数
    ``__le32  i_block[EXT4_N_BLOCKS];  // 指向具体的 block
    ``...
};
```

画外音：

通过 inode 找到数据快才是重点，这样数据库 可能存储在任何一个角落里

文件系统一开始就将 inode 与 block 规划好了，除非重新格式化

Superblock（超级区块）

```
block 与 inode 的总量;

未使用与已使用的 inode / block 数量;

block 与 inode 的大小 （block 为 1, 2, 4K，inode 为 128Bytes 或 256Bytes） ;

filesystem 的挂载时间、最近一次写入数据的时间、最近一次检验磁盘 （fsck） 的时间
等文件系统的相关信息;

一个 val
id bit 数值，若此文件系统已被挂载，则 valid bit 为 0 ，若未被挂载，则 valid bit
为

dumpe2fs -h /dev/sda2
```

2. 目录项对象（directory entry）

> 存储在哪里

不同于前面的两个对象，目录项对象没有对应的磁盘数据结构，VFS根据字符串形式的路径名临时创建它。而且由于目录项对象并非真正保存在磁盘上，所以目录项结构体没有是否被修改的标志。

> 什么是目录项 ，如何读取的

/ ,/etc,/etc/passwd 都是目录项

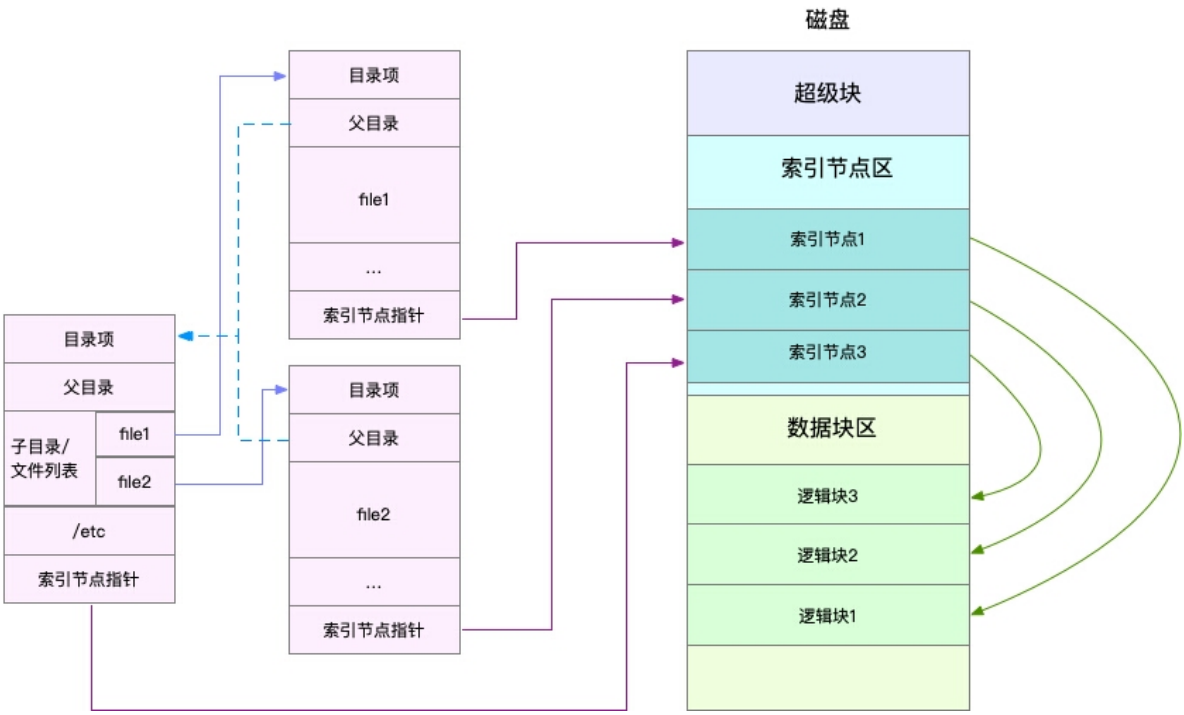

- node 本身并不记录文件名，文件名的记录 是在目录文件中

3. 缓存

- 缓存类型

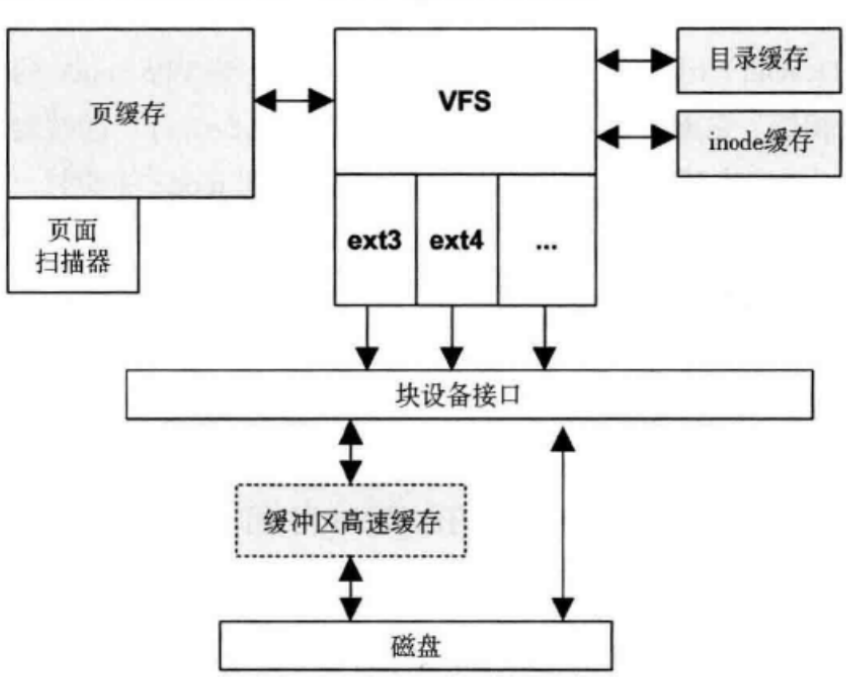

图 8.10　Linux 文件系统缓存

表 8.1　缓存类型示例

缓存	示例
页缓存	操作系统页缓存
文件系统主存	ZFS ARC
文件系统二级缓存	ZFS L2ARC
目录缓存	目录缓存，DNLC
inode 缓存	inode 缓存
设备缓存	ZFS vdev
块设备缓存	块缓存（buffer cache）

- 页缓存

8.3.6　写回缓存

写回缓存广泛地应用于文件系统，用来提高写性能。它的原理是，当数据写入主存后，就认为写入已经结束并返回，之后再异步地把数据刷入磁盘。文件系统写入“脏”数据的过程称为刷新（flushing）。例子如下：

1. 应用程序发起一个文件的 `write()` 请求，把控制权交给内核。
2. 数据从应用程序地址空间复制到内核空间。
3. `write()` 系统调用被内核视为已经结束，并把控制权交还给应用程序。
4. 一段时间后，一个异步的内核任务定位到要写入的数据，并发起磁盘的写请求。

图 8.2 描绘了在响应读操作的时候，存储在主存里的普通文件系统缓存情况。

读操作从缓存返回（缓存命中）或者从磁盘返回（缓存未命中）。未命中的操作被存
缓存中，并填充缓存（热身）。

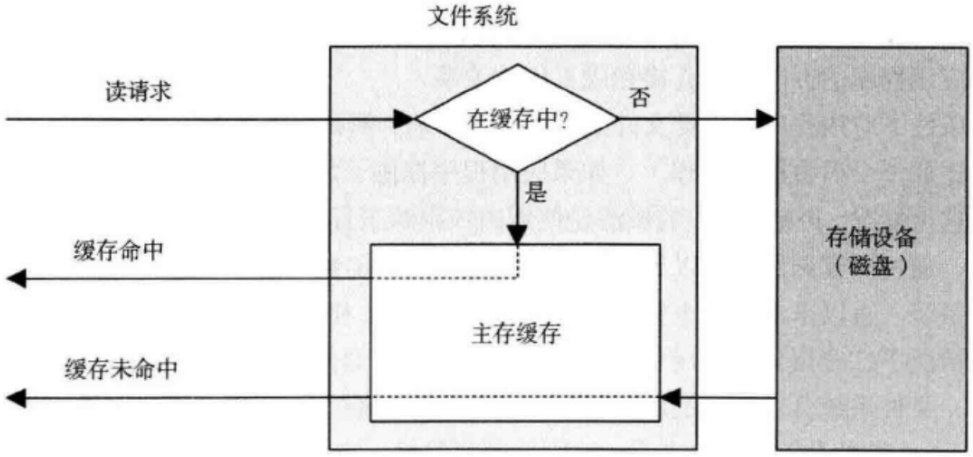

图 8.2　文件系统主存缓存

image-20191029172455029-

image-20191029172803543

image-20191029173304985

4 Linux 内核中文件 Cache 管理的机制

http://www.ilinuxkernel.com/files/Linux.Kernel.Cache.pdf

概念回顾

文件 Cache 是文件数据在内存中的副本，

文件 Cache 分为两个层面，一是 Page Cache， 另一个 Buffer Cache

- Page

image-20191101154937693

- 内存管理系统和 VFS 只与 Page Cache 交互

image-20191101152555437

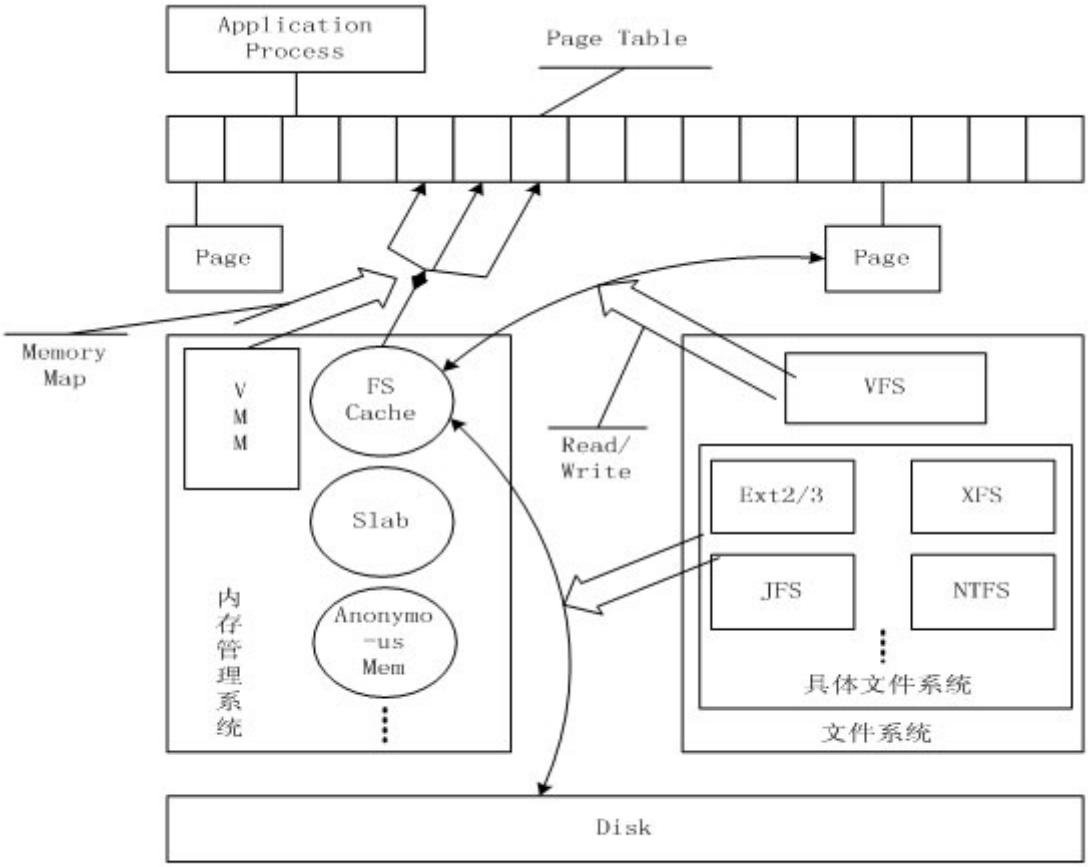

图 1　Linux 中文件 Cache 与相关部分关系示意图

- Page Cache、Buffer Cache、文件以及磁盘之间的关系

  文件的每个数据块最多只能对应一个 Page Cache 项 ，

  页面Cache中的每页所包含的数据是属于某个文件

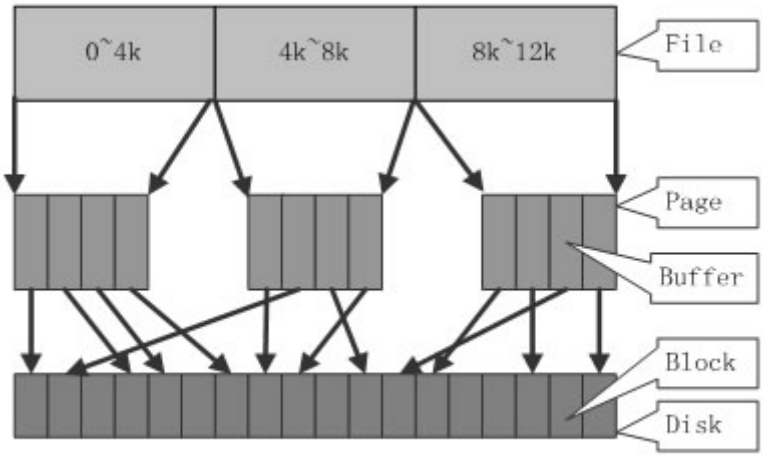

图2 文件、Page、Buffer、Block、Disk关系

- 每一个 Page Cache 包含若干 Buffer Cache

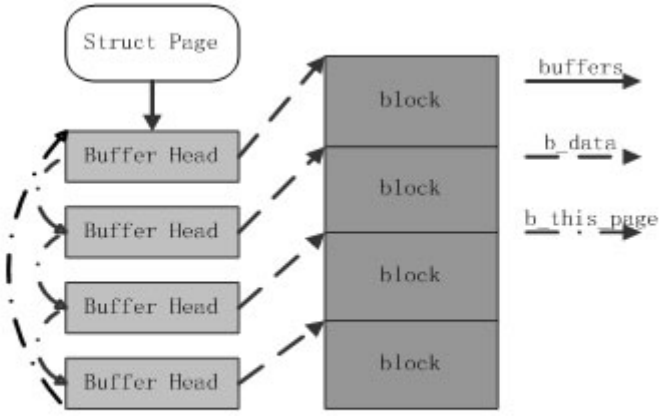

图 3　page/buffer_head 关系示意图

- **Page cache和Buffer cache的区别**

磁盘的操作有逻辑级（文件系统）和物理级（磁盘块），这两种Cache就是分别缓存逻辑和物理级数据的。

> 假设我们通过文件系统操作文件，那么文件将被缓存到Page Cache，
>
> 如果需要刷新文件的时候，Page Cache将交给Buffer Cache去完成，因为Buffer Cache就是缓存磁盘块的。

Page cache实际上是针对文件系统的，是文件的缓存，在文件层面上的数据会缓存到page cache。文件的逻辑层需要映射到实际的物理磁盘，这种映射关系由文件系统来完成。当page cache的数据需要刷新时，page cache中的数据交给buffer cache

案例实践

实验1： 查看文件系统 占用情况

- 文件系统中的目录项和索引节

```
# 按下 c 按照缓存大小排序，按下 a 按照活跃对象数排序

$ slabtop
Active / Total Objects (% used)    : 277970 / 358914 (77.4%)
Active / Total Slabs (% used)      : 12414 / 12414 (100.0%)
Active / Total Caches (% used)     : 83 / 135 (61.5%)
Active / Total Size (% used)       : 57816.88K / 73307.70K (78.9%)
Minimum / Average / Maximum Object : 0.01K / 0.20K / 22.88K

  OBJS ACTIVE  USE OBJ SIZE  SLABS OBJ/SLAB CACHE SIZE NAME
69804  23094   0%    0.19K   3324       21     13296K dentry
16380  15854   0%    0.59K   1260       13     10080K inode_cache
58260  55397   0%    0.13K   1942       30      7768K kernfs_node_cache
  485    413   0%    5.69K     97        5      3104K task_struct
 1472   1397   0%    2.00K     92       16      2944K kmalloc-2048
```

dentry 行表示目录项缓存，inode_cache 行，表示 VFS 索引节点缓存，其余的则是各种文件系统的索引节点缓存。

目录项和索引节点占用了最多的 Slab 缓存。

不过它们占用的内存其实并不大，加起来也只有 23MB 左右

- free 输出的 Cache，是页缓存和可回收 Slab 缓存的和（ vmstat free ）

```
$ cat /proc/meminfo | grep -E "SReclaimable|Cached"
Cached:           748316 kB
SwapCached:            0 kB
SReclaimable:     179508 kB


procs -----------memory---------- ---swap-- -----io---- -system-- ------cpu-----
 r  b   swpd   free   buff  cache   si   so    bi    bo   in   cs us sy id wa st
 1  0  81196 13122800 239084 2126152    0    0     0     1    0    0  1  0 99  0
 0
```

```
cat /proc/meminfo
MemTotal:       16267884 kB
MemFree:        13119460 kB
MemAvailable:   13798228 kB
Buffers:          240324 kB
Cached:          1648252 kB
SwapCached:         9644 kB
Active:           802676 kB
Inactive:        1733356 kB
Active(anon):     510300 kB
Inactive(anon):  1449420 kB
Active(file):     292376 kB
Inactive(file):   283936 kB
Unevictable:           0 kB
Mlocked:               0 kB
SwapTotal:       1048572 kB
SwapFree:         967376 kB
Dirty:               108 kB
Writeback:             0 kB
AnonPages:        639208 kB
Mapped:           109460 kB
Shmem:           1312244 kB
Slab:             478768 kB
SReclaimable:     355860 kB
SUnreclaim:       122908 kB
KernelStack:        5376 kB
PageTables:        10860 kB
NFS_Unstable:          0 kB
Bounce:                0 kB
WritebackTmp:          0 kB
CommitLimit:     9182512 kB
```

```
Committed_AS:    3782272 kB
VmallocTotal:   34359738367 kB
VmallocUsed:       34736 kB
VmallocChunk:   34359698684 kB
HardwareCorrupted:     0 kB
AnonHugePages:    253952 kB
HugePages_Total:       0
HugePages_Free:        0
HugePages_Rsvd:        0
HugePages_Surp:        0
Hugepagesize:       2048 kB
DirectMap4k:      108416 kB
DirectMap2M:    10377216 kB
DirectMap1G:     8388608 kB
```

- 可以用stat命令，查看某个文件的inode信息

```
 stat cmd.txt
  File: ‘cmd.txt’
  Size: 131             Blocks: 8          IO Block: 4096   regular file
Device: fd00h/64768d    Inode: 482         Links: 1
Access: (0644/-rw-r--r--)  Uid: (    0/    root)   Gid: (    0/    root)
Access: 2019-01-22 17:22:54.685741395 +0800
Modify: 2019-01-22 16:34:25.993178846 +0800
Change: 2019-01-22 16:34:25.993178846 +0800
 Birth: -

stat - display file or file system status

stat -f cmd.txt
  File: "cmd.txt"
    ID: 37fc5f360777ebb Namelen: 255     Type: ext2/ext3
Block size: 4096       Fundamental block size: 4096
Blocks: Total: 4817666    Free: 2971792    Available: 2748308
Inodes: Total: 1227328    Free: 1148127


df -i
Filesystem                Inodes  IUsed    IFree IUse% Mounted on
/dev/mapper/vg_root-root  1227328  79201  1148127    7% /
devtmpfs                  2030909    422  2030487    1% /dev
tmpfs                     2033485      1  2033484    1% /dev/shm
```

- 是否缓存 1631-->112

```
To free pagecache:
# echo 1 > /proc/sys/vm/drop_caches
To free dentries and inodes:
# echo 2 > /proc/sys/vm/drop_caches
```

```
To free pagecache, dentries and inodes:
# echo 3 > /proc/sys/vm/drop_caches


root@work:~# free -m
              total        used        free      shared  buff/cache   available
Mem:           2009         276         101           3        1631        1545
Swap:           425

root@work:~# echo 3 > /proc/sys/vm/drop_caches
root@work:~# free -m
              total        used        free      shared  buff/cache   available
Mem:           2009         250        1646           1         112        1628
Swap:
```

命令slabtop查看slab占用情况

Slab的两个主要作用：
Slab对小对象进行分配，不用为每个小对象分配一个页，节省了空间。
内核中一些小对象创建析构很频繁，Slab对这些小对象做缓存，可以重复利用一些相同的对象，减少内存分配次

https://fivezh.github.io/2017/06/25/Linux-slab-info/

```
[root@vm-10-115-37-60 bin]#  cat /proc/slabinfo |awk '{print $1,$3*$4/1024,"KB"}' | sort -k2 -n | tail
sysfs_dir_cache 2019.94 KB
kmalloc-1024 2080 KB
kmalloc-2048 2304 KB
kmalloc-4096 2528 KB
buffer_head 6515.74 KB
ext4_inode_cache 8439.27 KB
inode_cache 9396.84 KB
radix_tree_node 11705.1 KB
shmem_inode_cache 91290 KB
dentry 309050 KB
```

- nmon

```
wget http://sourceforge.net/projects/nmon/files/nmon16e_mpginc.tar.gz
tar -zxvf nmon16e_mpginc.tar.gz
cp nmon_x86_64_centos7 /usr/local/bin/nmon
cd /usr/local/bin
chmod 777 nmon
```

- vmtouch

http://ohmycat.me/2017/12/05/vmtouch.html

祝玩得开心！

参考

[1] https://github.com/freelancer-leon/notes/blob/master/kernel/vfs.md

https://wizardforcel.gitbooks.io/vbird-linux-basic-4e/content/59.html

https://www.cnblogs.com/xiaojiang1025/p/6363626.html

[2] directory entry cache (dcache). 是什么 https://www.kernel.org/doc/ols/2002/ols2002-pages-289-300.pdf

[3] 一次FIND命令导致的内存问题排查 https://ixyzero.com/blog/archives/3231.html

[4] 什么是PAGECACHE/DENTRIES/INODES? https://ixyzero.com/blog/archives/3233.html

[5] free https://zhuanlan.zhihu.com/p/35277219

[6] Linux Used内存到底哪里去了？ http://blog.yufeng.info/archives/2456

[7] x86 CPU中逻辑地址到物理地址映射过程 http://ilinuxkernel.com/?p=448

[8] https://zh.wikipedia.org/wiki/Inode

[9] http://www.ruanyifeng.com/blog/2011/12/inode.html